

インデックスを使いこなす

Yoshinori Matsunobu

Senior MySQL Consultant
Professional Services APAC
Sun Microsystems
Yoshinori.Matsunobu@sun.com



自己紹介

- 松信 嘉範 (まつのぶ よしのり)
- 2006年9月からMySQLシニアコンサルタントとして勤務
 - パフォーマンスチューニング、環境レビュー、MySQL Cluster、 ベストプラクティス等
 - APAC (日本およびアジア圏)を主担当
 - 日本、オーストラリア、ニュージーランド、シンガポール、インド、香港など
 - コンサルティング依頼を常時受付中
- 対外的な活動
 - 書籍(自著)
 - 現場で使えるMySQL (2006.3 翔泳社)
 - Javaデータアクセス実践講座 (2008.2 翔泳社)
 - 連載
 - Linux-DBサーバ構築入門 (翔泳社 DBマガジン)
 - 執筆依頼を随時受付中
 - 日程の事前確保が難しいので、勉強会/セミナー系よりも執筆系がメイン



本セッションの内容

- 検索処理とインデックス
 - B+Treeインデックスの構造
 - Covering Index
 - インデックス検索とフルテーブルスキャン
 - マルチカラムインデックスとインデックスマージ
 - ソート処理とインデックス
 - ケーススタディ: DBT-1
- 更新処理とインデックス
 - INSERTをすると何が起こるのか
 - 昇順INSERTとランダムINSERT
 - 昇順INSERTのためのアプローチ
- プラクティス (時間があれば)
- MyISAMインデックスとLinux I/Oスケジューラ (時間があれば)



ディスクI/O性能を意識する

CPUのアクセス時間: < 10ns

メモリのアクセス時間: < 60ns

HDDのアクセス時間: < 5ms

* シーク待ち+回転待ち+転送時間

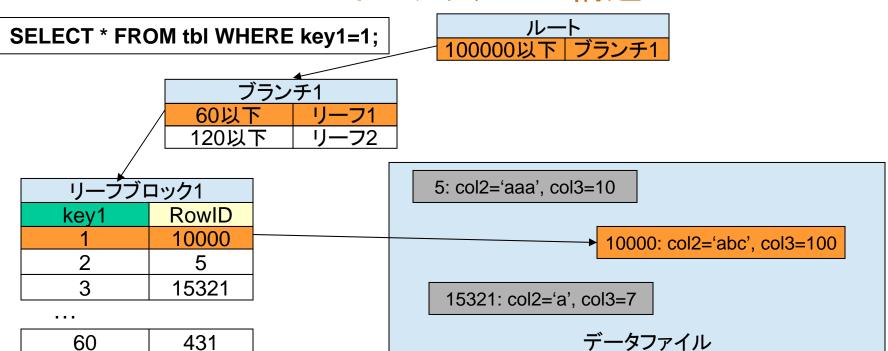
SSDのアクセス時間: < 0.5ms

HDDのアクセス時間が支配的 HDD+ライトキャッシュ+バッテリーバックアップで 書き込みは大きく緩和できるが、 読み取りは緩和できない

HDD→SSDで読み取りが大きく改善される 今後の普及に大きな期待



B+Treeインデックスの構造とI/O



- インデックスの内部では、インデックス列に対して昇順に格納されている
- インデックス検索のたどり方の基本形は、ルート→ブランチ→リーフ→データファイル
- ・キーに対応する行番号(RowID)から、データファイル上の場所を一意に特定できる
- ・I/Oの単位はブロック (InnoDBは16KB)
- 1つのブロックの中に数十以上のエントリがあるのが普通
- 読み取られたブロックは、メモリ上にキャッシュされる
- ・ルート、ブランチはほぼ確実にキャッシュされる
- ・テーブルが巨大な場合、リーフとデータファイルの中にはキャッシュされないものが出てくる
- <u>- 見積もりとしては、リーフとデータファイルで計2回のランダムディスクアクセスが起きると考える</u>



InnoDBのインデックス構造

セカンダリインデックス (主キー以外)

リーフブロック1	
PK	
10	
1	
3	

. . .

60	5

クラスタインデックス (主キー)

リーフブロック1		
PK 残りの列の値		
1	Col2='a', col3='2008-10-31'	
2	Col2='aaa', col3='2008-10-31'	
3	Col2='aaa', col3='2008-10-31'	

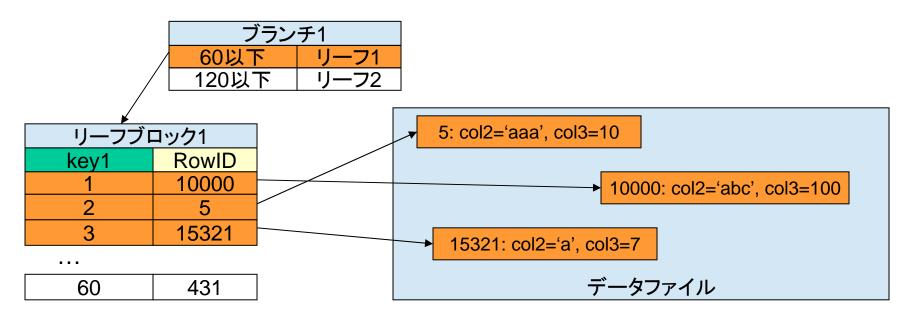
. .

- ・主キー以外のインデックス (セカンダリインデックス) には、インデックス値に対して 主キー値が対応 (RowIDではない)
- ・主キーインデックス (クラスタインデックス) には、主キー値に対して 残りの列値が対応 (RowIDではない)
- ・主キー検索では、1回のアクセスで全列値を取ることができるので高速
- ・主キー以外のインデックスでの検索は、セカンダリインデックスにアクセスした後、 クラスタインデックスにアクセスする必要があるのでオーバーヘッドが大きい
- 可能な限り主キー検索を行なうようにする
- ・可能な限り主キーは小さくする (INTEGER UNSIGNEDなど)
- クラスタインデックスは、セカンダリインデックスに比べてサイズが大きくなる



B+Treeインデックスの構造とI/O(範囲検索)

SELECT * FROM tbl WHERE key1 IN (1, 2, 3);

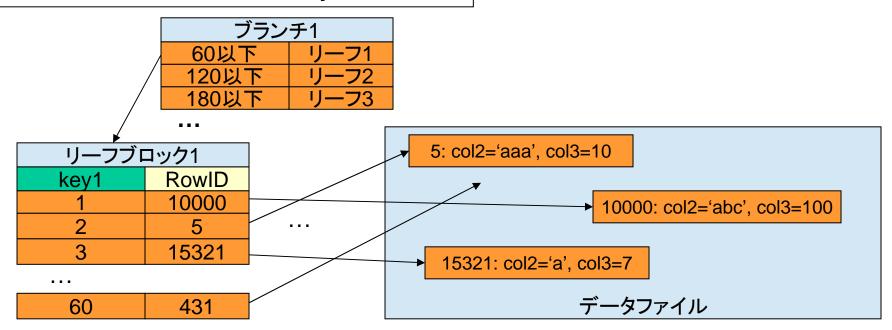


- ・通常の用途では、1つのブロックの中に数十以上のエントリがある
- ・したがって、key1の1,2,3は1つのブロック内におさまっていると考えられる →1回のI/O
- ・対応するRowIDはばらばらなので、データファイル上の配置も飛び飛び →各レコードを読むのにそれぞれ1回のI/Oが必要と考えられる
- ・見積もりとしては、リーフ1回、データファイル3回の計4回のランダムリードが発生
- ・一般化すると、N件の範囲検索では、1 + N回のランダムリードが発生しうる



インデックスの副作用

SELECT * FROM tbl WHERE key1 <= 1000000



- ・インデックス検索は、データファイルを読みに行く処理がランダムアクセスになる
- インデックスにヒットした件数だけデータファイルをランダムアクセスする
- ・100万件インデックスにヒットすれば、100万回ランダムアクセスする
- ・RDBMSの(コストベース)オプティマイザは、通常はこのような検索方式を選択せず、 フルテーブルスキャンを選択する



フルテーブルスキャン

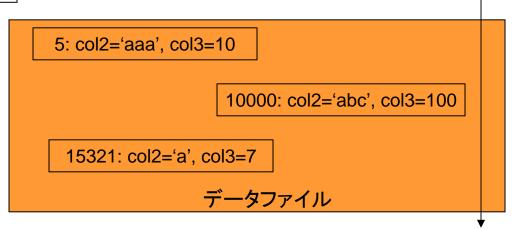
SELECT * FROM tbl WHERE key1 <= 1000000

ブランチ1	
60以下	リーフ1
120以下	リーフ2
120以下	リーフ3

フルテーブルスキャン

リーフブロック1	
key1	RowID
1	10000
2	5
3	15321

60	431

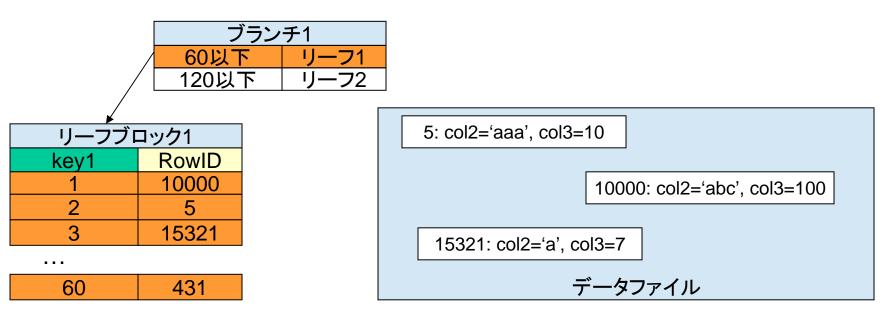


- ・フルテーブルスキャンは、テーブルの先頭から末尾までを順番に読んでいく
- ・I/O回数は100万回よりもずっと少なくなる
 - ・1つのブロックには複数のレコードがあるので、レコード数が100万でもブロック数はもっと少ない
 - •RDBMSの「先読み」機能により、フルテーブルスキャンでは複数のブロックを一度に読む
- このため、インデックススキャンよりもずっと効率が良い
- ・定説:アクセス範囲が10-15%以上になる場合はフルテーブルスキャンの方が効率が良い



Covering Index (インデックス「だけ」を読む検索)

SELECT key1 FROM tbl WHERE key1 IN (1, 2, 3);



- ・Covering Indexとは、データファイルを読まず、インデックスを読むだけで 処理を完結できる検索形態のこと
- この場合、リーフブロックを読むだけで処理が完結するので非常に高速
- 特に広範囲にまたがるアクセスで威力を発揮
- ・発生条件は、WHERE句、SELECT句などで指定するすべての列がインデックスに含まれていること
- →マルチカラムインデックスで狙いやすい 「SELECT * FROM」がアンチパターンだと言われる理由の1つ



Covering Indexの見分け方

> explain select count(*) from t1

id: 1

select_type: SIMPLE

table: t1

type: index

possible_keys: NULL

key: key1

key len: 5

ref: NULL

rows: 57705

Extra: Using index

> explain select count(c3) from t1

id: 1

select_type: SIMPLE

table: t1

type: ALL

possible_keys: NULL

key: NULL

key len: NULL

ref: NULL

rows: 57705

Extra:

・EXPLAINのExtraに「Using index」があれば、Covering indexになっている

・typeが「range」や「index」の場合、「Using index」を積極的に狙いたい



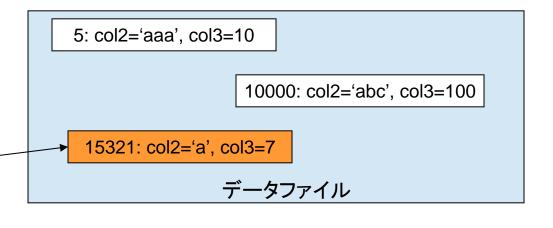
マルチカラムインデックスと インデックスマージ



マルチカラムインデックス

SELECT * FROM tbl WHERE keypart1 = 2 AND keypart2 = 3

リーフブロック1		
keypart1	keypart2	RowID
1	5	10000
2	1	5
2	2	4
2	3	15321
3	1	100
3	2	200
3	3	300
4	1	400



- •keypart1, keypart2の両方がAND条件で指定
- ・読み取るリーフブロック数は1個で済む
- マッチしたレコード数が1個なら、データファイルへのアクセスも1回で済む
- ・Disk Read回数は2回、となり、アクセス効率は悪くない



インデックスマージ

SELECT * FROM tbl WHERE key1 = 2 AND key2 = 3

key1のリーフ		
key1	RowID	
1	10000	
2	4	
2	5	
2	15321	
3	100	
3	200	
3	300	
4	400	

マージ処理

	key2のリーフ	
	key2	RowID
	1	10
	1	20
	1	30
	2	500
(2	1000
	3	200
) 	3	300
	3	15321

5: col2='aaa', col3=10

15321: col2='a', col3=7
データファイル

- ・key1、key2はそれぞれ別のインデックス
- それぞれのインデックスで条件一致判定
- ・マッチしたRowIDをそれぞれ比較(マージ)し、RowIDが一致したものが該当
- ・Disk Readの回数は3回、スキャンしたリーフエントリ数は6、さらにマージ処理が加わり、マルチカラムインデックスよりもオーバーヘッドが大きい
- ・各インデックスについて、マッチしたレコード数が多ければ多いほど処理に時間がかかる例:インデックスマージで0.1~0.2秒のクエリが、マルチカラムインデックス化によって0.01秒に

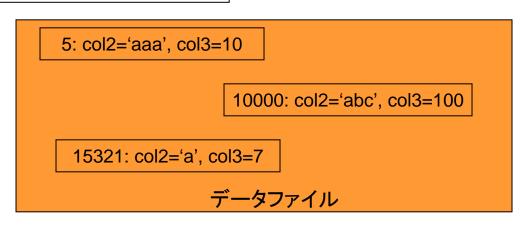


マルチカラムインデックスのきかない検索

SELECT * **FROM** tbl WHERE keypart2 = 3

SELECT * FROM tbl WHERE keypart1 = 1 OR keypart2 = 3

リーフブロック1			
•	keypart2		
1	5	10000	
2	1	5	
2	2	4	
2	3	15321	
3	1	100	
3	2	200	
3	3	300	
4	1	400	



- ・マルチカラムインデックスは、先頭列がWHERE条件で指定されない限り使われない
- •OR条件にはきかない
- インデックスマージは、どちらの場合にも効果がある

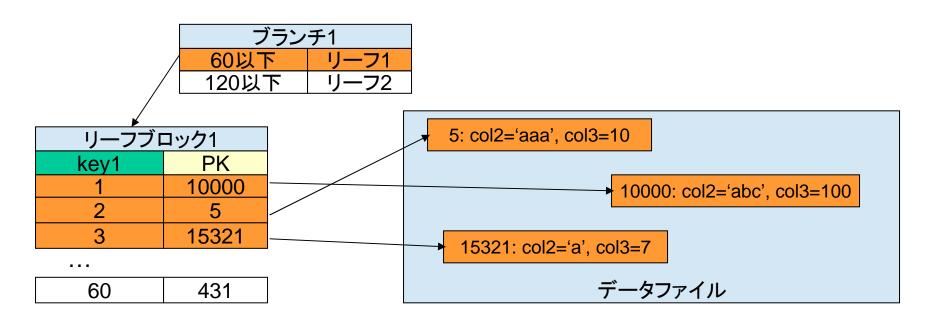


ソート処理とインデックス



ソート処理とインデックス

SELECT * FROM tbl WHERE key1 < 30 ORDER BY key1

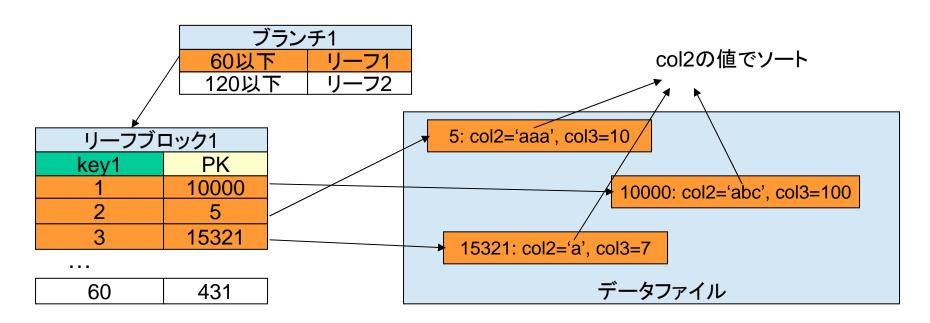


・インデックスはすでにソートされているため、インデックス対象列がソートに使われると、ソート処理そのものが必要ないので高速になる(ソートのオーバーヘッドが無い)



ソート処理とインデックス (2)

SELECT * FROM tbl WHERE key1 < 30 ORDER BY col2

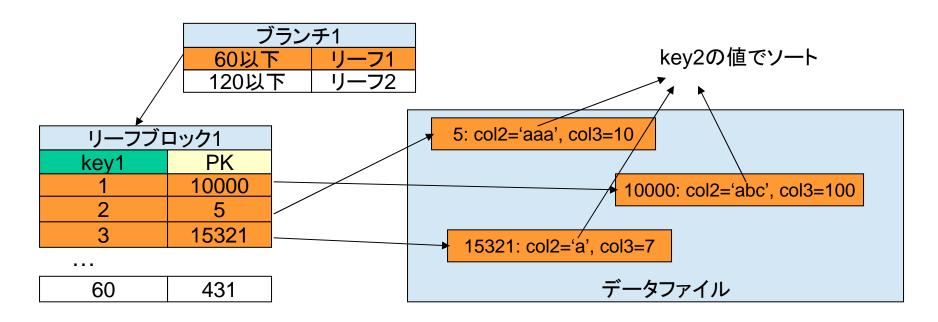


- ・ORDER BYの列がインデックス対象でないと、その列でソートをするために 結果を並べ替える必要がある。
- ・EXPLAINのExtraに「Using filesort」と出れば、ソートにインデックスが使われていないことを示している
- ・ソートしなければいけないレコードが多いほど、時間がかかる



ソート処理とインデックス (3)

SELECT * FROM tbl WHERE key1 < 30 ORDER BY key2



- ・2つの別々のインデックスがあっても、使われるのはどちらか片方 (この図はkey1が使われる場合を示している)
- ・key2が使われると「Using filesort」は起きない。しかし、「key1 < 30」の絞込みにインデックスが使えないので、全レコードをスキャンしなければならない
- ・key1とkey2のどちらのインデックスが使われるかは、場合による (MySQLのコストベース・オプティマイザによる判断)



ORDER BY LIMIT Nの落とし穴

SELECT * FROM tbl WHERE cond < 10000 ORDER BY keyX LIMIT 20

- ・上位N件を取るために、ORDER BY xxx LIMIT N は頻繁に使われる
- ・選択されうる実行計画は、以下の3種類

A: condがインデックスとして使われ、条件を満たしたレコードをソートし、上位20件を取得 (type=range, key=cond, Using filesort)

B: keyXがインデックスとして使われ、cond条件を満たすレコードが20件になったところで終了 (type=index, key=keyX)

C: condにインデックスが無く、フルテーブルスキャンをし、ソートし、上位20件を取得 (type=ALL, key=NULL, Using filesort)

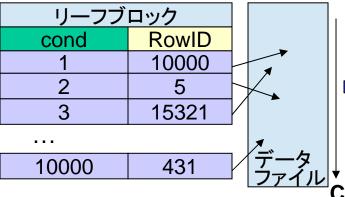
- どれが最も高速になるかは、「場合による」
- 適切な実行計画が選ばれないことがある



ORDER BY LIMIT Nの落とし穴

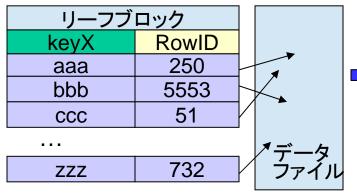
SELECT * FROM tbl WHERE cond < 10000 ORDER BY keyX LIMIT 20

A. condをインデックスとして使う



🔷 keyXでソート ➡上位20件を返す

B. keyXをインデックスとして使う



♪ Cond< 10000の条件判定

20個満たしたところで終了

Aが最適なケース:

cond < 10000を満たすレコードが ほとんど無い場合 (大量にあるとだめ)

Bが最適なケース:

cond < 10000を満たすレコードが 大量にある場合 (少ないとだめ)

Cが最適なケース:

condでインデックスが使えず、

Bの条件も満たさない場合

適切な実行計画が選ばれない場合、 FORCE INDEX, IGNORE INDEXヒントでコントロール



ケーススタディ: DBT-1 (Infamous IPA benchmarks)

```
SELECT i_id, i_title, a_fname, a_lname FROM item, author
WHERE i_title LIKE '%BABABAOGBABAIN%' AND i_a_id = a_id
ORDER BY i title ASC LIMIT 50;
select type: SIMPLE
      table: item
      type: index
possible keys: i i a id
        key: i i title
    key len: 63
        ref: NULL
       rows: 50
      Extra: Using where
******* 2. row
                            select_type: SIMPLE
      table: author
      type: eq ref
possible_keys: PRIMARY
       key: PRIMARY
    key len: 5
        ref: test.item.i a id
       rows: 1
```

前提条件:

- •itemには10000件、authorには2500件
- ・i titleには単独のインデックス
- •item, authorの順番でジョイン
- •a idはauthorテーブルの主キー
- ・LIKEの中間一致検索では
- インデックスは使えない
- ・WHERE句にマッチするレコードは

ほとんど無い

Extra:

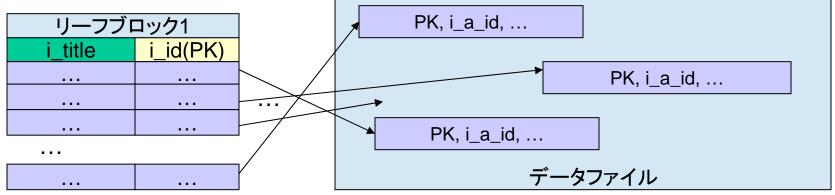


ケーススタディ: DBT-1 (2)

SELECT i_id, i_title, a_fname, a_lname FROM item, author WHERE i_title LIKE '%BABABAOGBABAIN%' AND i_a_id = a_id ORDER BY i_title ASC LIMIT 50;

Type=「index」でExtraに「Using index」が無いと何が起こるか

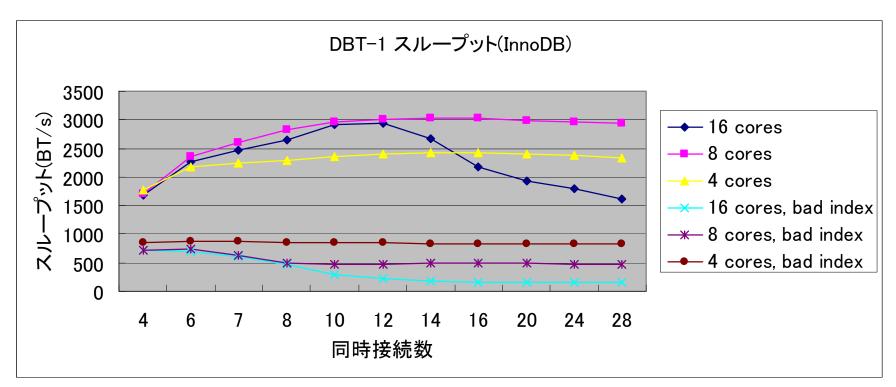
- •type=indexはフルインデックススキャン
- ・Using indexが無い場合は実レコードも読む



- インデックスを先頭から順番に読んでいく
- 対応するレコードをデータファイルから読む
- •WHERE句の一致判定をする
- •i_a_id列を用いてジョインし、対応するレコードがauthorテーブルにあるかどうか判定する
- ・マッチするレコードが50件になるか、すべてを読み終えるまで繰り返す
- ・DBT-1のデータの場合、条件を満たすレコードが5件しか無いので、インデックスを全件 読まないといけない
- ・InnoDBの場合、セカンダリインデックスのスキャンはCPUスケーラビリティを悪化させる



ケーススタディ: DBT-1 (3)



- ・下3本は、ORDER BY LIMIT Nで適切な実行計画が選ばれなかったケース。 IPAから発信されているベンチマーク結果は、これがベース
- ・上3本は、IGNORE INDEXヒントを使い、実行計画をコントロールしたケース
- ・実行計画が適切な場合は、8コアまでは普通にスケールしておりスループットは3000を超えている
- ・実行計画が不適切な場合は、8コアや16コアだと逆にスループットが落ちる。 最大の4コアでもスループットは3分の1以下。
- 5.0.58, innodb_thread_concurrency=0



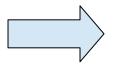
更新処理とインデックス



INSERTすると何が起こるのか

INSERT INTO tbl (key1) VALUES (61)

リーフブロック1		
key1	RowID	
1	10000	
2	5	
3	15321	
•••		
60	431	



リーフブロック1		
key1	RowID	
1	10000	
2	5	
3	15321	
60	431	

リーフブロック2	
key1	RowID
61	15322
空き状	:態

リーフブロックが一杯で、これ以上エントリが入らない

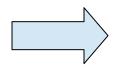
新しいリーフブロックが割り当てられて、 その中に追加される



昇順INSERT

INSERT INTO tbl (key1) VALUES (now())

リーフブロック1		
key1	RowID	
2008-08-01	10000	
2008-08-02	5	
2008-08-03	15321	
2008-10-29	431	



リーフブロック1		
key1	RowID	
2008-08-01	10000	
2008-08-02	5	
2008-08-03	15321	
2008-10-29	431	

リーフブロック2		
key1	RowID	
2008-10-29	431	
空き状態		

リーフブロックが一杯で、これ以上エントリが入らない

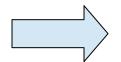
- 新しいリーフブロックが割り当てられて、 その先頭から入る
- ・日付など、インデックスの並び順に対して昇順に入るインデックスもある
- ・新しいブロックは、空のブロックを新規に割り当てる
- ・1ブロックをフルに利用する
- ・虫食い状態になりにくい
- ブロック数が少なくなる
- サイズが小さい。ゆえにキャッシュされやすい



ランダムINSERT

INSERT INTO tbl (key1) VALUES (31)

リーフブロック1		
key1	RowID	
1	10000	
2	5	
3	15321	
60	431	



リーフブロック1	
key1	RowID
1	10000
30	333
空き状態	

リーフブロック2	
key1	RowID
31	345
60	431
空き状態	

- ・通常、インデックスの並び順に対してレコードはランダム順に入る例: メッセージテーブルに対する、メンバーIDなど
- ・新しいブロックの中に、既存のブロックから半分移る
- ・虫食い状態になりやすい
- ・1ブロックあたりに占めるエントリ数が少なくなる傾向
- ブロック数が多くなる
- ・サイズが増える。ゆえにキャッシュされにくくなる



昇順INSERT vs ランダムINSERT

1000万件のレコードがすでに存在するテーブルに対して、 100万回追加INSERTするのにかかる時間と、インデックスサイズを測定

セカンダリインデックスの値を順番に入れていく (1000万1 .. 1100万) vs セカンダリインデックスの値をランダムに入れていく (1から1000万の間でランダム)

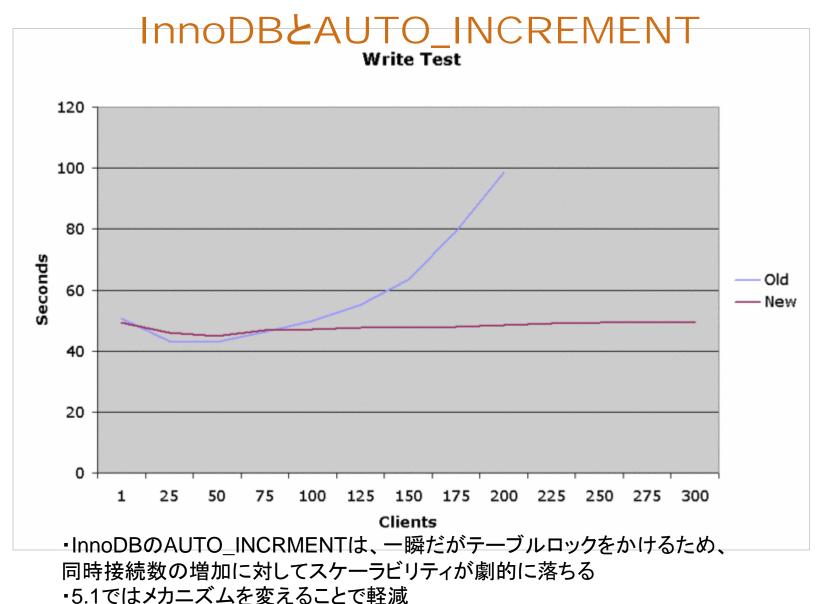
* どちらも、主キーはauto_increment まったく同じことを、インデックス数が3個の場合でも実験

インデックス数1個	昇順INSERT	ランダムINSERT
100万件INSERT時間	37.88秒	56.72秒
インデックスサイズ	161MB	335MB

インデックス数3個	昇順INSERT	ランダムINSERT
100万件INSERT時間	52.26秒	3分4秒
インデックスサイズ	483MB	1.06GB

インデックスに対して昇順にINSERTすることがいかに重要かが分かる InnoDBでは、特に主キーを昇順INSERTすることが重要







昇順INSERTのためのアーキテクチャ

Buffering insert(緩衝材) パターン

アプリケーション

INSERT/UPDATE

DELETE/REPLACE

Key1
100
5
7932
998
3325
1000









Sort + Bulk update

_	_
(ey	1

Key1
5
100
998
1000
3325
7932

- ・Web/Appサーバは緩衝材に対して更新して終了
- ・緩衝材から本体DBに対して更新
 - •非同期
 - データを主要インデックスに対して

昇順に並べ替える

・バルクINSERT/UPDATE/DELETE

緩衝材の候補:

- インデックスの無いテーブル
- ・キャッシュサーバ
- ・キュー



緩衝材:インデックスの無いテーブル

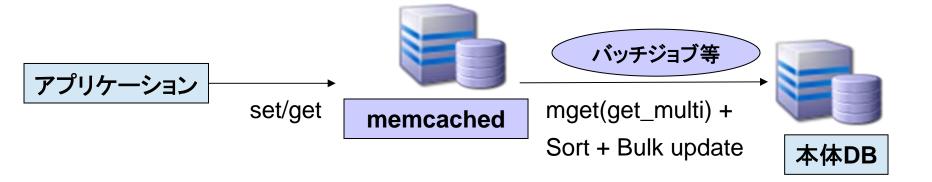


Key1	Key1
100	5
5	100
7932	998
998	1000
3325	3325
1000	7932

- ・本体DBと同じ列定義で、インデックスが無いテーブルを 緩衝サーバ上に用意
- ・時間/日付ごとに緩衝サーバ上のテーブル名を変えていく
- ・古いテーブルの中身を本体DBに移す
- 更新結果を即時に検索したい場合には向かない



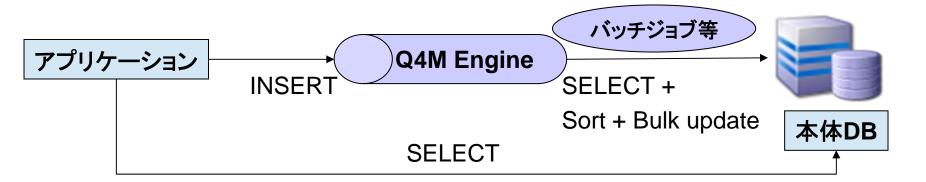
緩衝材:キャッシュサーバ (memcached)



- ・アプリケーションからはmemcachedにストアして終了(高速)
- ・バッチジョブなどが、後でまとめて値を本体DBに投入 (複数件をまとめて取り、ソートしてバルクupdate)
- ・検索処理は本体DBまたはmemcachedに向ける
- ・memcachedはクラッシュすると中身が失われるので注意が必要
- ・C/Perl/PHP/Ruby/Javaなどメジャーな言語用にライブラリが提供されている
- ・MySQL Enterprise購入ユーザには、memcachedも追加でサポート



緩衝材:キュー (Q4M Storage Engine)



- Q4M (Queue For MySQL: http://q4m.31tools.com)
- ・サイボウズラボ 奥 一穂氏が開発した、MySQLのカスタムストレージエンジン
- ・MySQL5.1で利用可能 (MySQL本体の再ビルドは不要)
- •クラッシュしてもデータは失われない
- •「mixiエコー」や「Pathtraq」など本番環境での実績がある
- ・バッチジョブなどを作成して、本体DBに反映
- ・検索処理は本体DBに向かう
- ・本体への反映の遅延を考慮して、memcachedなどに別途 最新データを置いておく手も有効



参考: Blackhole Storage Engine

アプリケーションからの更新



- マスターの更新負荷を軽減する上で効果的なストレージエンジン
- メリット:アプリケーション側の変更がいらない
- デメリット:発行されたSQL文がそのまま実行されるだけなので、 インデックス昇順INSERTの恩恵を受けることはできない





アプリケーションからの参照

- ・スレーブでは、ENGINE=InnoDBなどで テーブルを作っておく
- ・バイナリログ経由でINSERTが実行される
- →InnoDBなど通常のテーブルに格納



Bad Practice - インデックスの数が多すぎる

- インデックスの数が多すぎる
 - カラムごとにインデックス
 - 1テーブルに20個のインデックス
 - アクセスパターンを全部網羅
- インデックスが過度に多いと
 - 更新性能が落ちる
 - 消費サイズが増える
 - インデックスの利用効率が落ちると、キャッシュ効率が悪くなり 検索性能も落ちる
- 必要なもの「だけ」にインデックスを作る



Bad Practice - インデックスが大きすぎる

- 例
 - URL (20~100バイト級)
 - UUID (36バイト)
- 現象
 - スペースを消費し、パフォーマンス悪化
 - 投入順序と並び順が一致していなければ、断片化が大きく発生する
- 対処策
 - Prefix Index機能を使い、先頭Nバイトだけをインデックス化する(例:INDEX col(5))
 - 代替となるインデックスを別に用意する
 - CRC32()による4バイトハッシュ値をインデックスに使うと、サイズを小さくできる

```
url varchar(255) index(url)
SELECT xx FROM tbl WHERE url='http://.....';
```

url_hash integer unsigned, index(url_hash)
SELECT xx FROM tbl WHERE url='http://......'
AND url_hash= CRC32('http://......');

 \rightarrow



Bad Practice – データ型の不正比較

- SELECT xx FROM t1 WHERE varchar_column = 1;
 - varchar_columnにインデックスがあっても、使われない
 - varchar_column = "1"と指定しなければならない
 - varchar_column = 1の場合、"001","01", "1.00"なども条件を満たす。
 - 文字列型は、文字順に並ぶ
 - 001
 - 002
 - 003
 - 01
 - 02
 - 1
 - 1.00
 - 2
 - この条件でインデックスを使うことはできない
- データ型を合わせるのは定石の1つ



Bad Practice - 無意味なマルチカラムインデックス

- マルチカラムインデックスの1列目を指定していない
 - SELECT xx FROM t1 WHERE key_part2 = xx;
- 1列目で範囲検索、2列目以降でイコール検索
 - SELECT xx FROM t1 WHERE key_part1 between 100 AND 105 AND key_part2 = 'abcde';
- 「Using index」に落とし込むために、意図的に余分な列をインデック スに入れることがある
 - SELECT id FROM tbl WHERE c1 = xx AND (c2 = xx or c3 = xx) で、c1,c2,c3をマルチカラムインデックスに



Bad Practice - ハッシュインデックスで範囲検索(できない)

- create table working_table (c1 int, c2 int, index(c1)) engine=memory;
- 100万件くらい投入
- 1万件ずつSELECTを100回繰り返すことを意図して、
- select * from working_table where c1 between 1 and 10000;
- フルテーブルスキャンになる
- MEMORYは、デフォルトで「ハッシュインデックス」を作り、「Btreeインデックス」を作らない
- ハッシュインデックスはイコール検索しかできず、範囲検索(<, >, BETWEEN, LIKEなど)はできない
- create table working_table (c1 int , index using btree(c1)) engine=memory;



Bad Practice - データ準備の欠如

- テストデータが
 - 10ユーザしかない
 - 100万ユーザいるけど、10ユーザしかテストでは使わない
 - 全ユーザが同じ商品を注文することになっている
- データ量が少ないと全部キャッシュされるので、 読み取り時にディスクアクセスが発生しない
- データ量が多くても、アクセス範囲が狭ければ全部 キャッシュされる
- データに偏りがあるとインデックス戦略が変わる
 - ORDER BY LIMITなど
- 不適切なインデックスがあっても、それに気づきにくい
- 本番のアクセスパターンと全く違うテストは 負荷テストの意味がまったく無い
- せめて量と偏りだけは考えておく



まとめ

- ランダムアクセス回数を最小化することが インデックス検索性能を高める鍵
- EXPLAINを使い、実行計画を注視する
 - 範囲検索は、Covering Indexへの帰結を狙う
 - 必要に応じ、FORCE/IGNORE INDEXによってコントロールする
- データ型、データサイズなど基本を守る
- 更新性能を抜本的に高めるためには、 昇順INSERTが有効